Examen_final_SUBRA_ileana

2026-10-30

```r
# Nombre d'échantillons par station
n <- 15

# Création des stations avec factor car les valeurs ne sont pas numériques.
station <- factor(rep(c("A", "V", "E"), each = n),
                  levels = c("A", "V", "E"))

# Température des sédiments et fixation pour la reproductibilité
set.seed(2026)

tempera <- c(
  rnorm(n, mean = 14, sd = 1.2),
  rnorm(n, mean = 16, sd = 1.2),
  rnorm(n, mean = 17, sd = 1.2)
)

# Matière organique
# Hypothèse : 1000 essais suivant une loi binomiale par échantillon avec une
# proportion moyenne de poids sec de 2.5%.
mat_org <- rbinom(3*n, size = 1000, prob = 0.025) / 1000

# Influence urbaine, on établit différentes probabilités selon les stations
# A=50%, V=85% et E=60%
inf_urb <- c(
  rbinom(n, size = 1, prob = 0.50),
  rbinom(n, size = 1, prob = 0.85),
  rbinom(n, size = 1, prob = 0.60)
)

inf_urb <- ifelse(inf_urb == 1, "OUI", "NON")

# Quantité totale de bactéries suivant une loi log normale
CFU_tot <- rlnorm(3*n,
                  meanlog = log(10000), # médiane théorique à 10000 CFU/g
                  sdlog = 0.18) # paramètre de dispertion

# Création du tableau avec nos données
donnees <- data.frame(
  station,
  tempera,
  mat_org,
  inf_urb,
  CFU_tot
)
```

```r
# Affichage des données
print(donnees)
```

```
##    station  tempera mat_org inf_urb   CFU_tot
## 1        A 14.62471   0.032     NON  7029.059
## 2        A 12.70437   0.028     NON 13037.519
## 3        A 14.16709   0.028     OUI  9180.723
## 4        A 13.89830   0.022     OUI 11931.666
## 5        A 13.20003   0.023     NON  7200.865
## 6        A 10.98069   0.023     OUI  9541.733
## 7        A 13.11782   0.029     NON  8414.807
## 8        A 12.77585   0.023     OUI  9155.290
## 9        A 14.13627   0.027     OUI  8237.292
## 10       A 13.43145   0.023     OUI 10687.574
## 11       A 13.51014   0.019     NON 12447.416
## 12       A 13.12348   0.030     NON  9149.446
## 13       A 13.73428   0.024     OUI  9598.279
## 14       A 13.72902   0.018     OUI  8186.515
## 15       A 10.94374   0.020     NON 11963.197
## 16       V 17.61640   0.020     OUI 11064.196
## 17       V 16.73969   0.027     OUI  7545.980
## 18       V 16.26108   0.026     NON 13055.101
## 19       V 15.03434   0.022     OUI  8102.140
## 20       V 16.82770   0.026     OUI  8274.865
## 21       V 15.60559   0.024     OUI  7672.580
## 22       V 15.80238   0.031     OUI  8066.877
## 23       V 14.32957   0.019     OUI  9392.850
## 24       V 17.75899   0.023     OUI 11006.579
## 25       V 16.05785   0.020     OUI  8798.728
## 26       V 18.28970   0.017     OUI  9648.158
## 27       V 18.07713   0.026     OUI  9506.140
## 28       V 16.06978   0.020     NON 12346.243
## 29       V 16.77439   0.020     OUI 15097.921
## 30       V 18.07075   0.029     OUI  8249.816
## 31       E 16.36524   0.024     OUI 14093.333
## 32       E 17.19967   0.020     OUI 14677.397
## 33       E 16.69433   0.026     OUI 10425.422
## 34       E 17.39934   0.029     OUI 11752.140
## 35       E 17.21892   0.024     OUI  7312.626
## 36       E 18.39751   0.018     NON 10880.560
## 37       E 17.71219   0.023     NON  9066.973
## 38       E 15.92986   0.024     OUI  9706.643
## 39       E 17.69270   0.017     NON 11044.969
## 40       E 16.01011   0.024     OUI 12044.216
## 41       E 15.61130   0.024     OUI  9917.223
## 42       E 17.93360   0.027     NON 16079.616
## 43       E 15.55493   0.016     NON 11118.453
## 44       E 17.36806   0.019     NON  9642.276
## 45       E 15.99961   0.031     OUI 10827.248
```

```r
# Vérification de nos données
str(donnees)
```

```
## 'data.frame':    45 obs. of  5 variables:
##  $ station: Factor w/ 3 levels "A","V","E": 1 1 1 1 1 1 1 1 1 1 ...
```

```
##  $ tempera: num  14.6 12.7 14.2 13.9 13.2 ...
##  $ mat_org: num  0.032 0.028 0.028 0.022 0.023 0.023 0.029 0.023 0.027 0.023 ...
##  $ inf_urb: chr  "NON" "NON" "OUI" "OUI" ...
##  $ CFU_tot: num  7029 13038 9181 11932 7201 ...
```

```
summary(donnees)
```

```
##  station    tempera         mat_org          inf_urb             CFU_tot
##  A:15    Min.   :10.94   Min.   :0.01600   Length:45          Min.   : 7029
##  V:15    1st Qu.:13.90   1st Qu.:0.02000   Class :character   1st Qu.: 8415
##  E:15    Median :16.00   Median :0.02400   Mode  :character   Median : 9648
##          Mean   :15.57   Mean   :0.02367                      Mean   :10271
##          3rd Qu.:17.22   3rd Qu.:0.02700                      3rd Qu.:11752
##          Max.   :18.40   Max.   :0.03200                      Max.   :16080
```

```
# Exportation en CSV pour exploiter les données
write.csv(donnees, "donnees_microbiologie.csv",
          row.names = FALSE)
```

```
# On charge le fichier et on génère les donées
source("generate_resistant_bacteria.R")
donnees <- generate_resistant_bacteria(donnees)

# On vérifie le résultat et les colonnes
head(donnees)
```

```
##   station  tempera mat_org inf_urb   CFU_tot CFU_rst
## 1       A 14.62471   0.032     NON  7029.059    3114
## 2       A 12.70437   0.028     NON 13037.519    3061
## 3       A 14.16709   0.028     OUI  9180.723    3610
## 4       A 13.89830   0.022     OUI 11931.666    4341
## 5       A 13.20003   0.023     NON  7200.865    2076
## 6       A 10.98069   0.023     OUI  9541.733     456
```

```
str(donnees)
```

```
## 'data.frame':    45 obs. of  6 variables:
##  $ station: Factor w/ 3 levels "A","V","E": 1 1 1 1 1 1 1 1 1 1 ...
##  $ tempera: num  14.6 12.7 14.2 13.9 13.2 ...
##  $ mat_org: num  0.032 0.028 0.028 0.022 0.023 0.023 0.029 0.023 0.027 0.023 ...
##  $ inf_urb: chr  "NON" "NON" "OUI" "OUI" ...
##  $ CFU_tot: num  7029 13038 9181 11932 7201 ...
##  $ CFU_rst: int  3114 3061 3610 4341 2076 456 2353 2218 3211 3349 ...
```

```
# On ajoute la colonne CFU_rst
donnees$CFU_rst <- generate_resistant_bacteria(donnees)$CFU_rst
names(donnees)
```

```
## [1] "station" "tempera" "mat_org" "inf_urb" "CFU_tot" "CFU_rst"
```

```
View(donnees)
```

```
# On définit la proportion de bacteries resistantes
prop <- donnees$CFU_rst / donnees$CFU_tot

# Transformation logarithmique en base 10 de la proportion
log_prop <- log10(prop + 1)

# Statistiques par station
```

```r
# La moyenne
moyennes <- aggregate(
  log_prop ~ station,
  data = donnees,
  FUN = mean
)

# La mediane
medianes <- aggregate(
  log_prop ~ station,
  data = donnees,
  FUN = median
)

# L'écart-type
ecarts_types <- aggregate(
  log_prop ~ station,
  data = donnees,
  FUN = sd
)

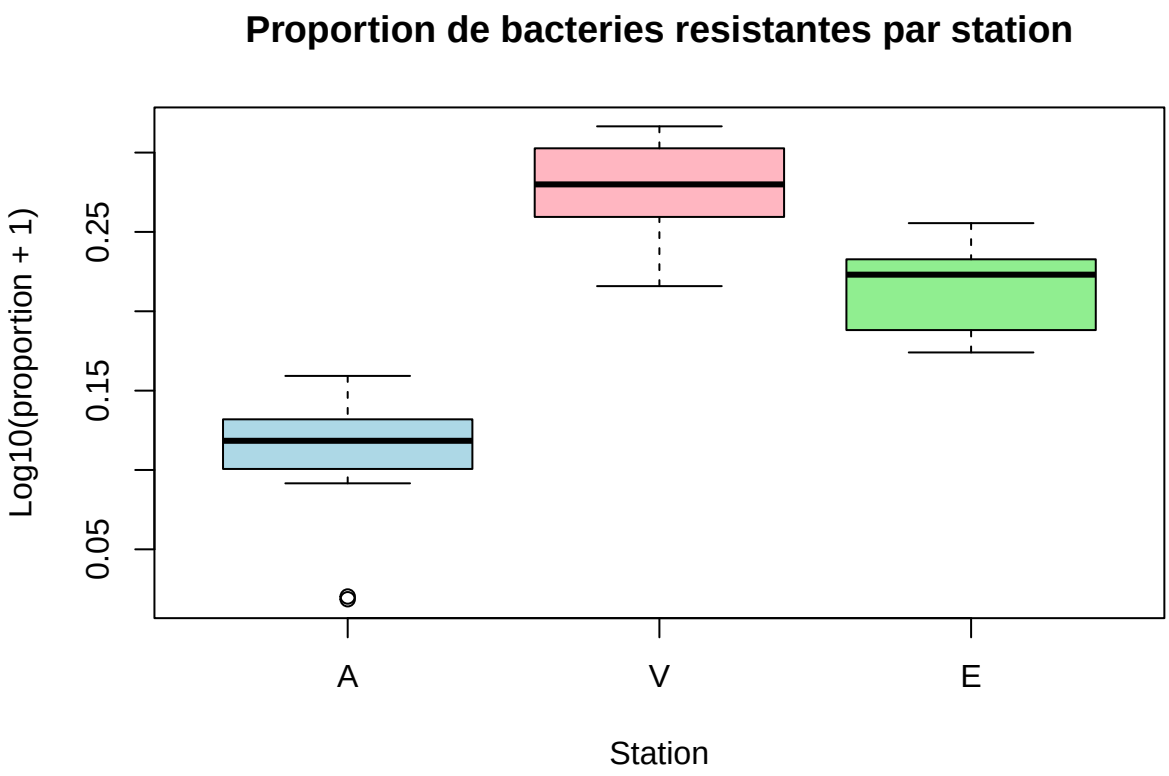
# On crée un tableau recapitulatif
resultats <- data.frame(
  Station = moyennes$station,
  Moyenne = moyennes$log_prop,
  Mediane = medianes$log_prop,
  Ecart_type = ecarts_types$log_prop
)

print(resultats)
```

```
##   Station   Moyenne   Mediane Ecart_type
## 1       A 0.1084937 0.1183820 0.04069039
## 2       V 0.2760238 0.2799520 0.02973710
## 3       E 0.2130713 0.2230732 0.02624245
```

On remarque que la moyenne et la médiane les plus élevées concernent la station V et les plus faibles concernent la station A. Il y a donc en moyenne une proportion plus élevée de bactéries résistantes au niveau du rejet urbain. Au contraire, on observe une moindre proportion moyenne en amont.

```r
# Graphique boite a moustaches
boxplot(
  log_prop ~ station,
  data = donnees,
  main = "Proportion de bacteries resistantes par station",
  xlab = "Station",
  ylab = "Log10(proportion + 1)",
  col = c("lightblue","lightpink", "lightgreen")
)
```

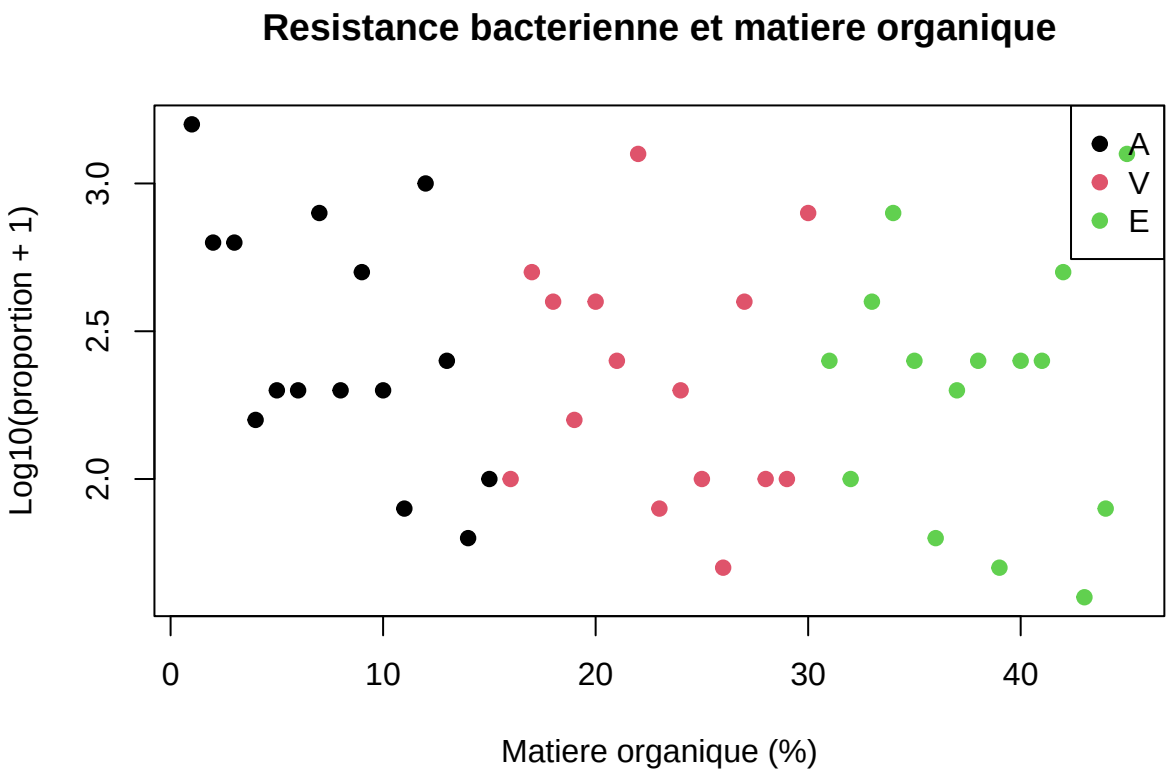


Sur ce graphique, on observe une médiane plus élevée pour la station V, intermédiaire pour la station E et plus faible pour la station A. Cela nous permet de mieux visualiser les résultats obtenus précédemment.

```
# Graphique de la matiere organique

plot(
  donnees$mat_org * 100,
  donnees$log_prop,
  col = as.numeric(donnees$station),
  pch = 19,
  xlab = "Matiere organique (%)",
  ylab = "Log10(proportion + 1)",
  main = "Resistance bacterienne et matiere organique"
)

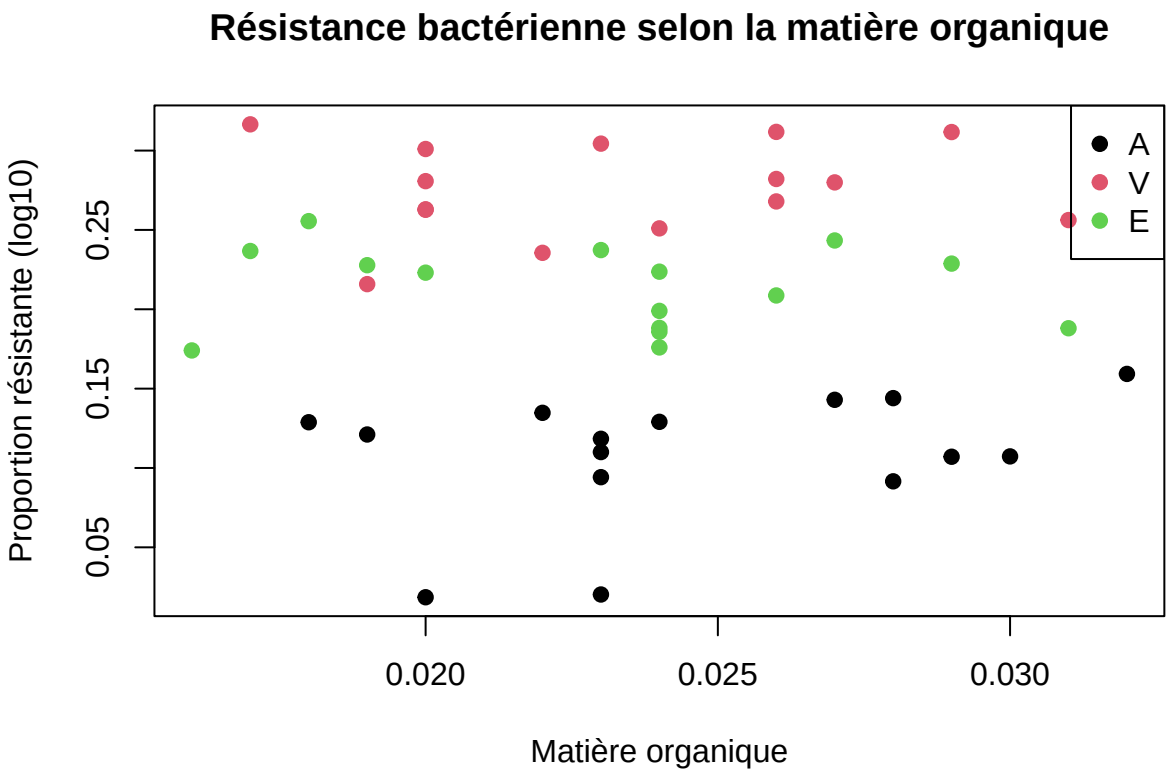
legend(
  "topright",
  legend = c("A", "V", "E"),
  col = 1:3,
  pch = 19
)
```



Sur ce graphique on observe .

```
plot(donnees$mat_org, log_prop,
     col = donnees$station,
     pch = 19,
     main = "Résistance bactérienne selon la matière organique",
     xlab = "Matière organique",
     ylab = "Proportion résistante (log10)")

legend(
  "topright",
  legend = c("A", "V", "E"),
  col = 1:3,
  pch = 19
)
```



Sur ce graphique on observe que la concentration en matière organique n'impacte pas la présence de résistance bactérienne. En effet, on observe la présence de résistance pour chaque station à toutes les concentrations en matière organique. On remarque cependant une stratification avec des valeurs plus faibles pour la station A, intermédiaire pour la station E et plus élevées pour la station V.

On réalise ensuite un test de corrélation de Pearson afin de vérifier s'il y a une corrélation ou non entre nos variables.

```
by(donnees, donnees$station, function(d) {
  cor.test(d$mat_org, log_prop[donnees$station == d$station[1]],
           method = "pearson")
})
```

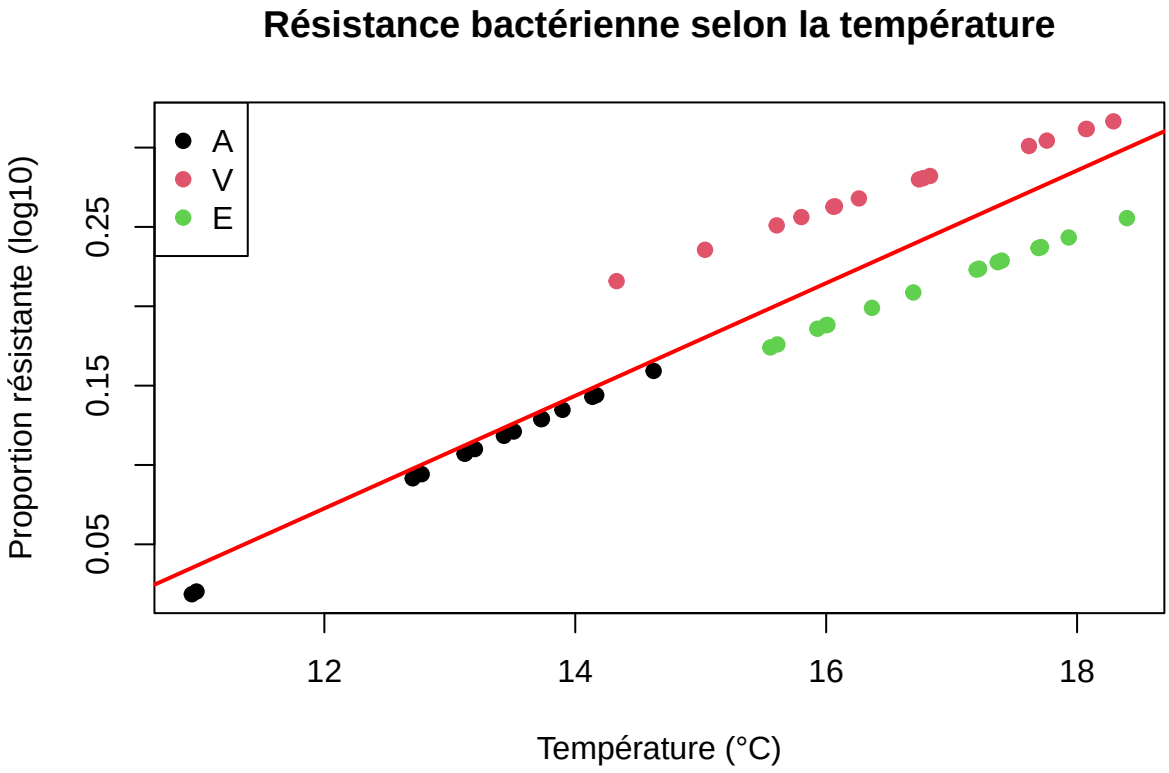
```
## donnees$station: A
##
##  Pearson's product-moment correlation
##
## data:  d$mat_org and log_prop[donnees$station == d$station[1]]
## t = 1.2528, df = 13, p-value = 0.2323
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  -0.2212349  0.7195116
## sample estimates:
##       cor
## 0.3282259
##
## ------------------------------------------------------------
## donnees$station: V
```

```
##
##  Pearson's product-moment correlation
##
## data:  d$mat_org and log_prop[donnees$station == d$station[1]]
## t = 0.3759, df = 13, p-value = 0.7131
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  -0.4314882  0.5848890
## sample estimates:
##       cor
## 0.1036948
##
## ------------------------------------------------------------
## donnees$station: E
##
##  Pearson's product-moment correlation
##
## data:  d$mat_org and log_prop[donnees$station == d$station[1]]
## t = -0.59515, df = 13, p-value = 0.562
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  -0.6231363  0.3812059
## sample estimates:
##        cor
## -0.1628598
```

Les résultats étant très proches de 0 et les p-value étant toutes supérieures à 0.05, on peut dire que les résultats ne sont pas significarifs. On en déduit donc qu'il n'y a pas de corrélation entre la proportion de résistance et la concentration en matière organique pour chacune des stations.

```r
plot(donnees$tempera, log_prop,
     col = donnees$station,
     pch = 19,
     main = "Résistance bactérienne selon la température",
     xlab = "Température (°C)",
     ylab = "Proportion résistante (log10)")

legend(
  "topleft",
  legend = c("A", "V", "E"),
  col = 1:3,
  pch = 19
)
abline(lm(log_prop ~ donnees$tempera), col = "red", lwd = 2)
```



Sur ce graphique, on peut voir que les bactéries résistantes de la station A sont distribuées entre 0 et 16°C et à des proportions plus faibles que les autres stations, c'est-à-dire entre 0 et 0.15. Celles de la station V sont distribuées entre 14 et 19°C à des proportions entre 0.20 et 0. 30. Enfin, celles de la station E entre 15 et 19°C et à des proportions entre 0.15 et 0.25. On peut donc estimer que les bactéries résistantes de la station A sont plus sensibles à des températures moyennes que celles des deux autres stations.

On fait un test de corrélation de Pearson afin de vérifier les résultats annoncés par le graphique.

```
by(donnees, donnees$station, function(d) {
  cor.test(d$tempera, log_prop[donnees$station == d$station[1]],
           method = "pearson")
})
```

```
## donnees$station: A
##
##  Pearson's product-moment correlation
##
## data:  d$tempera and log_prop[donnees$station == d$station[1]]
## t = 72.284, df = 13, p-value < 2.2e-16
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  0.9961550 0.9995994
## sample estimates:
##       cor
## 0.9987583
##
## ------------------------------------------------------------
## donnees$station: V
```

```
##
##  Pearson's product-moment correlation
##
## data:  d$tempera and log_prop[donnees$station == d$station[1]]
## t = 100.16, df = 13, p-value < 2.2e-16
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  0.9979944 0.9997912
## sample estimates:
##       cor
## 0.9993527
##
## ------------------------------------------------------------
## donnees$station: E
##
##  Pearson's product-moment correlation
##
## data:  d$tempera and log_prop[donnees$station == d$station[1]]
## t = 143.38, df = 13, p-value < 2.2e-16
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  0.9990204 0.9998981
## sample estimates:
##      cor
## 0.999684
```

Les résultats étant très proches de 1 et les p-value bien inférieures à 0.05, on peut dire qu'il y a bien une corrélation positive entre la température et la proportion de résistance bactérienne.

On réalise ensuite un test de Shapiro afin de s'assurer que les données suivent ou non une distribution normale.

```
by(log_prop, donnees$station, shapiro.test)
```

```
## donnees$station: A
##
##  Shapiro-Wilk normality test
##
## data:  dd[x, ]
## W = 0.83572, p-value = 0.01097
##
## ------------------------------------------------------------
## donnees$station: V
##
##  Shapiro-Wilk normality test
##
## data:  dd[x, ]
## W = 0.95349, p-value = 0.581
##
## ------------------------------------------------------------
## donnees$station: E
##
##  Shapiro-Wilk normality test
##
## data:  dd[x, ]
## W = 0.93397, p-value = 0.3125
```

Dans le cas de ce test, la station A dispose d'une p-value inférieure à 0.05, on doit donc rejeter l'hypothèse de normalité des données. Pour les deux autres stations, la p-value est supérieure à 0.05. Alors pour les stations V et E on ne rejette pas l'hypothèse de la normalité.

```
# On test l'homogénéité des variances entre les stations.
fligner.test(log_prop ~ station, data = donnees)
```

```
##
##  Fligner-Killeen test of homogeneity of variances
##
## data:  log_prop by station
## Fligner-Killeen:med chi-squared = 0.0067856, df = 2, p-value = 0.9966
```

On utilise le test de Fligner-Killeen car la normalité n'est pas respectée pour toutes les stations. La p-value étant supérieure à 0.05, elle est significative. Donc on ne rejette pas l'hypothèse selon laquelle il n'y a pas de différence. On peut en déduire qu'il n'y a pas de différence significatives entre les variances des différentes stations.

```
# On teste alors la différence de moyenne de log_prop :
kruskal.test(log_prop ~ donnees$station)
```

```
##
##  Kruskal-Wallis rank sum test
##
## data:  log_prop by donnees$station
## Kruskal-Wallis chi-squared = 37, df = 2, p-value = 9.237e-09
```

On a choisi un test de Kruskal-Wallis car nous avions besoin de tester plus de 2 valeurs qui étaient indépendantes. Le résultat de la p-value étant très inférieure à 0.05, donc significatif, on rejette l'hypothèse qu'il n'y a pas de différence entre les moyennes. On peut donc en déduire qu'il y a une différence sans pour autant savoir d'où elle vient.

Pour savoir d'où vient la différence on utilise donc le test de Dunn avec correction de Holm. Tous nos groupes ne suivant pas la normalité ce test est applicable.

```
install.packages("FSA", repos = "https://cloud.r-project.org")
```

```
## Installation du package dans 'C:/Users/ilean/AppData/Local/R/win-library/4.4'
## (car 'lib' n'est pas spécifié)
```

```
## le package 'FSA' a été décompressé et les sommes MD5 ont été vérifiées avec succés
##
## Les packages binaires téléchargés sont dans
##  C:\Users\ilean\AppData\Local\Temp\RtmpuoyjJb\downloaded_packages
```

```
library(FSA)
```

```
## Warning: le package 'FSA' a été compilé avec la version R 4.4.3
```

```
## ## FSA v0.10.1. See citation('FSA') if used in publication.
## ## Run fishR() for related website and fishR('IFAR') for related book.
```

```
dunnTest(log_prop ~ donnees$station,
         method = "holm")
```

```
##   Kruskal-Wallis rank sum test
##
## data: x and g
```

```
## Kruskal-Wallis chi-squared = 37.0002, df = 2, p-value = 0
```

```
##
##                       Dunn's Pairwise Comparison of x by g
##                                       (Holm)
##
## Col Mean-
## Row Mean            A          V
##
##        V    -6.074719
##                0.0000*
##
##        E    -3.308428   2.766291
##                0.0019*    0.0057*
##
## FWER = 0.05
## Reject Ho if adjusted p  FWER with stopping rule, where (unadjusted) p = Pr(|Z|  |z|)
## Dunn (1964) Kruskal-Wallis multiple comparison
##
##   p-values adjusted with the Holm method.
```

```
##   Comparison         Z      P.unadj        P.adj
## 1      A - V -6.074720 1.242043e-09 3.726129e-09
## 2      A - E -3.308429 9.382107e-04 1.876421e-03
## 3      V - E  2.766291 5.669788e-03 5.669788e-03
```

Pour ce test, nos résultats ajustés sont tous significatifs avec des p-value largement inférieures à 0.05. Il y a donc des différences significatives entre chaque groupe. Cependant on remarque une différence plus grande entre les stations A et V.

On en conclu donc que la station V est celle qui dispose du plus grand nombre de bactéries résistantes. Il faudrait alors tester si cela est dû ou non au fait que la station est située au niveau des rejets urbains.

```
# On visualise sous forme de tableau l'influence urbaine selon les stations.
table(donnees$station, donnees$inf_urb)
```

```
##
##     NON OUI
##   A   7   8
##   V   2  13
##   E   6   9
```

```
# On détermine la proportion de l'influence selon les stations
prop.table(table(donnees$station, donnees$inf_urb), margin = 1)
```

```
##
##           NON       OUI
##   A 0.4666667 0.5333333
##   V 0.1333333 0.8666667
##   E 0.4000000 0.6000000
```

On remarque une proportion proche de l'équilibre pour la station A. Pour la station E, on remarque un léger déséquilibre en faveur de l'influence urbaine. Enfin, pour la station V on observe un déséquilibre très net en faveur de l'influence urbaine.

On teste alors s'il existe une association entre la station et l'influence grâce à un test de Chi2.

```
chisq.test(table(donnees$station, donnees$inf_urb))
```

```
##
##  Pearson's Chi-squared test
```

```
##
## data:  table(donnees$station, donnees$inf_urb)
## X-squared = 4.2, df = 2, p-value = 0.1225
```

Pour le Chi2, la p-value est supérieure à 0.05 donc on ne peut pas rejeter l'hypothèse d'indépendance.

On souhaite ensuite explorer le lien entre log_prop et les variables température et matière organique. Pour cela on doit crée un modèle linéaire généralisé.

On insère donc nos variables dans un modèle que l'on précise gaussien car log_prop est une variable quantitative continue.

```
modele <- glm(log_prop ~ tempera + mat_org,
              data = donnees,
              family = gaussian())

summary(modele)
```

```
##
## Call:
## glm(formula = log_prop ~ tempera + mat_org, family = gaussian(),
##     data = donnees)
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -0.356501   0.049023  -7.272 5.95e-09 ***
## tempera      0.035512   0.002436  14.577  < 2e-16 ***
## mat_org      0.123001   1.159394   0.106    0.916
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for gaussian family taken to be 0.00101576)
##
##     Null deviance: 0.260030  on 44  degrees of freedom
## Residual deviance: 0.042662  on 42  degrees of freedom
## AIC: -177.55
##
## Number of Fisher Scoring iterations: 2
```

On obtient alors un coefficien d'environ 0.035 pour la température avec une p-value inférieure à 0.05. Il y a donc association positive de la température et de la concentration en bactéries résistantes. Pour chaque degré de température supplémentaire, la concentration augmente de 0.035 unités pour un quantité de matière organique constante. Concernant la matière organique, bien qu'ayant un coefficient positif de 0.12, sa p-value est de 0.919 donc bien supérieure à 0.05. Cette valeur n'étant pas significative, on ne peut donc pas établir de lien entre la quantité de matière organique et la proportion de bactéries.

De manière générale, nous avons pu mettre en évidence une influence de la température sur la proportion de bactéries résistantes. Celà grâce au test de Pearson mais aussi grâce au modèle linéaire. Cependant , aucun lien n'a pu être fait par rapport à la quantité de matière organique présente. Enfin, aucun lien certain n'a pu être mis en évidence entre la proportion de bactéries résistantes et l'influence urbaine.